UNIVERSIDAD DEL CARIBE

Ingeniería en Datos e Inteligencia Organizacional — 7mo Semestre

Asignatura: Visualización de Datos

PROYECTO 4:
“LA MOVILIDAD URBANA Y EL TRÁFICO INTELIGENTE”

Entregable Oficial — Fase 1: Análisis y Preprocesamiento de Datos

Atributo del Proyecto	Especificación Técnica y Metodológica
Tema	Transporte, ciudades inteligentes (Smart Cities) y sostenibilidad urbana
Fuente de Datos Oficial	NYC Taxi & Limousine Commission (TLC) Trip Record Data (Enero 2025)
Volumen Procesado	3,475,226 registros crudos → 3,202,368 registros limpios (92.15% retenido) + 265 zonas
Arquitectura Frontend	React 18 + TypeScript + Vite + Tailwind CSS + Recharts/Plotly + Leaflet (GeoJSON)
Motor de Base de Datos	PostgreSQL 16 + Extensión Geoespacial PostGIS (Alojado en Supabase / Neon)
Control de Versiones y Despliegue	Repositorio Público en GitHub + Despliegue Continuo en Vercel
Metodología Aplicada	Metodología de Desarrollo de Paneles de Control por Fases (Mendiola, 2023)

Contenido del Documento de Justificación (Fase 1):

• 1. Introducción y Arquitectura Tecnológica del Proyecto (React + PostgreSQL + GitHub).

• 2. Tarea 1: Análisis e Identificación de Requerimientos de la Audiencia y Descomposición de Preguntas Clave.

• 3. Tarea 2: Definición de Objetivos y Justificación del Tipo de Dashboard (Táctico / Analítico y 8 Dimensiones).

• 4. Tarea 3: Preprocesamiento de Datos Reales (NYC Yellow Taxi Enero 2025 + Catálogo de Zonas + Shapefile):

- 3.1 Identificación y entendimiento de variables (Muestra visual primeras/últimas 5 filas, estadísticos y frecuencias).

- 3.2 Limpieza de datos (Variables redundantes, análisis de valores nulos y reglas de imputación/filtrado).

- 3.3 Manejo y eliminación justificada de valores atípicos (Outliers con diagramas de caja y dispersión).

- 3.4 Integración de datos de múltiples fuentes y Modelo Relacional/DDL en PostgreSQL.

1. Introducción y Requisitos Técnicos del Proyecto

El presente documento fundamenta y justifica las decisiones conceptuales, analíticas y técnicas correspondientes a la **Fase 1 (Análisis)** del Proyecto 4: *"La movilidad urbana y el tráfico inteligente"*. El proyecto explora el comportamiento de la movilidad en la ciudad de Nueva York a través de los registros oficiales de la **NYC Taxi and Limousine Commission (TLC)**, evaluando patrones de congestión vial, eficiencia operativa, costos por milla, propinas y densidad espacial de demanda.

Componente	Tecnología Seleccionada	Justificación Técnica
Gestión de Código	GitHub (Repositorio Público) + Vercel	Permite control de versiones colaborativo mediante ramas (GitFlow), trazabilidad de commits y despliegue web continuo accesible públicamente.
Frontend Web	React + Vite + Tailwind CSS + Recharts + React-Leaflet	React ofrece renderizado eficiente basado en componentes y estados reactivos para filtros interactivos (horas pico, distritos, tipo de día) sin recargar la página.
Base de Datos	PostgreSQL + PostGIS	Motor relacional robusto capaz de indexar millones de viajes, ejecutar agregaciones analíticas rápidas (KPIs, cuartiles, series horarias) y cruzar polígonos geográficos de las 263 zonas.
Pipeline ETL	Python (PyArrow + Pandas + GeoPandas + SQLAlchemy)	Procesa archivos columnares Apache Parquet (.parquet) de alta densidad, aplica reglas de limpieza de outliers e inserta las tablas optimizadas en PostgreSQL.

2. Tarea 1: Análisis e Identificación de Requerimientos de la Audiencia

Siguiendo la metodología de desarrollo de paneles de control, el primer paso crítico consiste en caracterizar quiénes utilizarán el dashboard, qué decisiones tomarán a partir de sus indicadores y cuál es su grado de alfabetización visual.

2.1. Respuesta a las 4 Preguntas Clave de la Audiencia

Pregunta Metodológica	Análisis y Respuesta Aplicada al Proyecto de Movilidad Urbana
1. ¿A quién va dirigido el dashboard y qué conoce sobre el tema?	• **Audiencia Primaria:** Planificadores urbanos, ingenieros de tránsito municipal (NYC DOT / TLC) y gestores de movilidad sostenible. • **Audiencia Secundaria:** Coordinadores de flotas de transporte (taxis y vehículos de alquiler) e investigadores de ciencia de datos urbanos. • **Conocimiento del tema:** Nivel **medio-alto**. Dominan conceptos como hora pico (Peak Hours), hora valle, tarifa por milla, recargo por congestión (CBD Congestion Fee), velocidad comercial (MPH) y la división territorial en 5 distritos (Boroughs) y 263 zonas.
2. ¿Qué información necesitan y qué decisiones tomarán?	• **Autoridades y Planificadores:** Necesitan identificar las zonas con mayor densidad de recogidas (Pickup Density) y las franjas horarias donde cae la velocidad promedio y aumenta la duración del viaje. *Decisiones:* Ajustar políticas de tarificación por congestión, priorizar carriles exclusivos y sincronización semafórica. • **Gestores de Flotas:** Necesitan conocer dónde y cuándo es más rentable operar (tarifa por milla y propinas promedio según zona y tipo de día). *Decisiones:* Redistribuir unidades hacia zonas de alta demanda (ej. Midtown, Upper East Side, JFK) reduciendo kilómetros en vacío.
3. ¿Poseen conocimiento previo de visualizaciones de datos?	Poseen familiaridad **intermedia-alta** con gráficos estadísticos y cartográficos. Se seleccionan visualizaciones estándar pero de alto poder analítico: **Mapa de calor coroplético** (relaciones espaciales), **Series temporales de líneas** (tendencias horarias/diarias), **Histogramas** (distribuciones de tarifas y distancias) y **Diagramas de caja y bigotes / Boxplots** (comparación de dispersión y cuartiles entre horas pico y valle).
4. ¿Cuáles son sus expectativas?	Esperan un panel interactivo donde puedan filtrar por rango horario (Pico vs. Valle), tipo de día (Laboral vs. Fin de semana) y Distrito (Borough), obteniendo respuesta inmediata a las preguntas clave de congestión, demanda, costos y propinas.

2.2. Descomposición de Expectativas en Preguntas Clave, Columnas y Funciones de Cálculo

Para transformar las expectativas de la audiencia en visualizaciones concretas dentro del dashboard en React, se desglosa cada pregunta clave identificando las columnas exactas del dataset de la NYC TLC y la función matemática de agregación:

Expectativa / Pregunta Clave	Columnas de la Fuente de Datos	Función de Cálculo	Visualización / KPI Asociado
P1. Demanda Espacial: ¿Cuáles son las zonas y distritos con mayor volumen de viajes iniciados?	• PULocationID (Viajes) • LocationID, Borough, Zone (Catálogo) • geometry (Shapefile)	• Conteo: COUNT(trip_id) • Proporción: (COUNT zona / Total) × 100	• KPI: Zona Top Demanda • Mapa de Calor (Leaflet/Plotly) • Gráfico de Barras Top Zonas
P2. Patrones Temporales: ¿Cómo evoluciona el flujo de viajes por hora del día y entre semana vs. fin de semana?	• tpep_pickup_datetime • Variables derivadas: pickup_hour (0-23), is_weekend, pickup_date	• Conteo horario: COUNT(*) • Promedio diario por hora: AVG(viajes_hora)	• Serie Temporal (Gráfico de Líneas de viajes por hora y por día)
P3. Congestión y Eficiencia: ¿Cómo varía la duración y velocidad de los viajes en Hora Pico en comparación con Hora Valle?	• tpep_pickup_datetime • tpep_dropoff_datetime • trip_distance • is_peak_hour	• Duración: (dropoff - pickup)/60 • Promedio: AVG(duration_min) • Cuartiles: Min, Q1, Mediana, Q3, Max	• KPIs: Duración y Distancia Promedio • Boxplot Comparativo (Hora Pico vs. Hora Valle)
P4. Estructura de Costos: ¿Cómo se distribuyen las tarifas y distancias, y cuál es la tarifa promedio por milla?	• fare_amount • total_amount • trip_distance	• Cociente promedio: AVG(fare_amount / trip_distance) • Frecuencia por intervalos (Bins)	• KPI: Tarifa Promedio por Milla ($/mi) • Histogramas de Tarifas y Distancias
P5. Comportamiento de Propinas: ¿Cuál es la propina promedio según la zona de origen y el tipo de día?	• tip_amount • payment_type (=1 Tarjeta) • PULocationID → Borough • day_type (Laboral/FinSem)	• Promedio: AVG(tip_amount) • % Propina: AVG(tip_amount / fare_amount) × 100	• KPI: Propina Promedio ($) • Gráfico Comparativo de Propinas por Zona y Tipo de Día

3. Tarea 2: Definición de Objetivos y Selección del Tipo de Dashboard

3.1. Definición del Objetivo del Dashboard y Problema que Resuelve

• **Objetivo General:** Desarrollar un dashboard web interactivo en React conectado a PostgreSQL que permita analizar y visualizar los patrones de movilidad urbana, congestión vehicular y eficiencia del transporte en Nueva York a partir de los registros de viajes de la NYC TLC, facilitando la identificación de horarios críticos de tráfico, zonas de máxima demanda y el rendimiento económico por milla.

• **¿Qué problema resuelve este dashboard?:** Resuelve la dificultad de procesar e interpretar millones de registros crudos de viajes urbanos, transformándolos en indicadores accionables que evidencian dónde ocurren los cuellos de botella viales, cuánto tiempo adicional pierden los ciudadanos en horas pico (+14.3% de caída en velocidad comercial) y cómo se concentra el 40% de la demanda de transporte en menos del 4% del territorio de la ciudad.

3.2. Justificación del Tipo de Dashboard Seleccionado

De acuerdo con la clasificación organizacional (*Operativo, Táctico, Estratégico*) y la tipología funcional de la metodología (*Operativo, Estratégico, Analítico*), se selecciona un **Dashboard Táctico con Enfoque Analítico**:

Criterio de Clasificación	Selección	Justificación Metodológica y Operativa
Enfoque Organizacional (Requisitos del Proyecto)	Táctico	No es *Operativo* porque no monitorea GPS en tiempo real minuto a minuto para despacho inmediato; ni es puramente *Estratégico* de alta dirección a 5-10 años. Es **Táctico** porque evalúa el rendimiento a corto y mediano plazo (mensual, semanal y por franjas horarias), ayudando a gerentes de tránsito y coordinadores de flota a tomar decisiones tácticas sobre horarios pico, asignación zonal y tarifas.
Tipología Metodológica (Mendiola, 2023)	Analítico	Procesa un gran volumen de datos históricos consolidados (más de 3.2 millones de viajes limpios) con precisión estadística para identificar tendencias temporales, correlaciones espaciales y distribuciones de probabilidad (cuartiles e histogramas), presentando un nivel de complejidad intermedio/normal.

3.3. Caracterización en las 8 Dimensiones Metodológicas

#	Dimensión	Clasificación	Justificación Aplicada al Dashboard de Movilidad NYC
1	Alcance	Específico	Enfocado específicamente en el sector de movilidad urbana, congestión vial y servicio de taxis regulados por la NYC TLC.
2	Tipo de Datos	Cuantitativos y Cualitativos	Cuantitativos: distancia (mi), duración (min), tarifas ($), propinas ($). Cualitativos: Distrito (Borough), Zona, Franja (Pico/Valle), Tipo de día.
3	Área de Aplicación	Transporte y Smart Cities	Transporte urbano, ciudades inteligentes y sostenibilidad (con componente financiero por el análisis de tarifas, peajes y recargos de congestión).
4	Tipo de Medida	Con Indicadores Clave (KPI)	Incluye 5 KPIs principales en tarjetas superiores: Duración promedio, Distancia promedio, Tarifa/milla, Zona Top Demanda y Propina promedio.
5	Tiempo	Histórico	Analiza series históricas consolidadas (Enero 2025) para descubrir patrones cíclicos horarios y semanales.
6	Interactividad	Interactivo	Permite aplicar filtros dinámicos en React (rango de horas, hora pico/valle, fin de semana/laboral, distrito) actualizando todas las vistas.
7	Nivel de Detalle	Alto	Permite desglosar desde métricas globales de toda la ciudad hasta cada una de las 263 zonas geográficas y las 24 horas del día.
8	Punto de Vista	Mixto (Exploratorio / Prescriptivo)	Combina modo Push (KPIs y hallazgos explícitos de congestión a primera vista) con modo Pull (exploración libre mediante filtros interactivos).

4. Tarea 3: Preprocesamiento de Datos (Análisis Exploratorio Real)

Tal como establece la metodología, el preprocesamiento y entendimiento de los datos representa cerca del 80% del esfuerzo del proyecto. Se realizó el análisis exploratorio sobre las tres fuentes oficiales de la NYC TLC: (1) el archivo de viajes **yellow_tripdata_2025-01.parquet** (**3,475,226 filas y 20 columnas**), (2) el catálogo **taxi_zone_lookup.csv** (**265 zonas**) y (3) el archivo geoespacial **taxi_zones.shp** (**263 polígonos**).

4.1. Identificación y Entendimiento de las Variables (3.1)

Se clasificaron las variables en **cualitativas** (categóricas/identificadores que responden al *¿Qué?, ¿Dónde?, ¿Cómo?*) y **cuantitativas** (numéricas continuas o discretas que responden al *¿Cuánto?*), contabilizando sus valores únicos exactos:

Variable	Clasificación	Tipo Dato	Valores Únicos	Descripción y Significado Operativo
VendorID	Cualitativa Nominal	int32	4	Proveedor TPEP (1=CMT, 2=Curb, 6=Myle, 7=Helix).
tpep_pickup_datetime	Cuantitativa Temporal	datetime64	1,672,077	Fecha y hora exacta en que se activó el taxímetro (inicio).
tpep_dropoff_datetime	Cuantitativa Temporal	datetime64	1,671,993	Fecha y hora exacta en que se detuvo el taxímetro (fin).
PULocationID	Cualitativa Nominal	int32	261	ID de Zona TLC de origen (recogida del pasajero, 1 a 265).
DOLocationID	Cualitativa Nominal	int32	260	ID de Zona TLC de destino (bajada del pasajero, 1 a 265).
RatecodeID	Cualitativa Nominal	float64	7	Tipo de tarifa (1=Estándar, 2=JFK, 3=Newark, 4=Nassau, 5=Negociada).
payment_type	Cualitativa Nominal	int64	6	Método de pago (1=Tarjeta, 2=Efectivo, 3=Sin cargo, 4=Disputa, 0=Flex).
store_and_fwd_flag	Cualitativa Binaria	string	2	Indicador de viaje guardado en memoria local por falta de red (Y/N).
passenger_count	Cuantitativa Discreta	float64	10	Número de pasajeros reportados en el vehículo (0 a 9).
trip_distance	Cuantitativa Continua	float64	4,545	Distancia recorrida en millas medida por el taxímetro.
fare_amount	Cuantitativa Continua	float64	11,538	Tarifa base por tiempo y distancia calculada por el taxímetro (USD).
tip_amount	Cuantitativa Continua	float64	4,197	Propina pagada en USD (registrada automáticamente solo en tarjeta).
tolls_amount	Cuantitativa Continua	float64	1,234	Monto total de peajes pagados durante el trayecto (USD).
congestion_surcharge	Cuantitativa Continua	float64	3	Recargo estatal NYS por congestión vial ($2.50 estándar).
cbd_congestion_fee	Cuantitativa Continua	float64	3	Nuevo cargo MTA por Zona de Alivio de Congestión ($0.75 desde ene-2025).
Airport_fee	Cuantitativa Continua	float64	7	Recargo de recogida en aeropuertos LaGuardia y JFK ($1.75).
total_amount	Cuantitativa Continua	float64	21,995	Costo total cobrado al pasajero (incluye recargos y propina en tarjeta).
duration_min (Derivada)	Cuantitativa Continua	float64	18,410	Duración del viaje en minutos: (dropoff - pickup) / 60.

Muestra Visual de los Datos (Primeras 5 Filas y Últimas 5 Filas)

Siguiendo las recomendaciones generales de la metodología (pág. 19), la inspección de las primeras y últimas 5 filas del dataset reveló un hallazgo crucial: las últimas 540,149 filas corresponden a viajes *Flex Fare* (payment_type = 0) donde las columnas passenger_count, RatecodeID, store_and_fwd_flag y congestion_surcharge vienen como NaN, aunque conservan íntegros sus tiempos, ubicaciones, distancias y tarifas:

Posición / Índice	tpep_pickup_datetime	tpep_dropoff_datetime	PU / DO ID	pass_cnt	trip_dist (mi)	pay_type	fare ($)	tip ($)	total ($)	cbd_fee ($)
Fila 0 (Inicio)	2025-01-01 00:18:38	2025-01-01 00:26:59	229 → 237	1.0	1.60	1 (Card)	10.00	3.00	18.00	0.00
Fila 1 (Inicio)	2025-01-01 00:32:40	2025-01-01 00:35:13	236 → 237	1.0	0.50	1 (Card)	5.10	2.02	12.12	0.00
Fila 2 (Inicio)	2025-01-01 00:44:04	2025-01-01 00:46:01	141 → 141	1.0	0.60	1 (Card)	5.10	2.00	12.10	0.00
Fila 3 (Inicio)	2025-01-01 00:14:27	2025-01-01 00:20:01	244 → 244	3.0	0.52	2 (Cash)	7.20	0.00	9.70	0.00
Fila 4 (Inicio)	2025-01-01 00:21:34	2025-01-01 00:25:06	244 → 116	3.0	0.66	2 (Cash)	5.80	0.00	8.30	0.00
Fila 3,475,221 (Fin)	2025-01-31 23:01:48	2025-01-31 23:16:29	79 → 237	NaN	3.35	0 (Flex)	15.85	0.00	20.60	0.75
Fila 3,475,222 (Fin)	2025-01-31 23:50:29	2025-02-01 00:17:27	161 → 116	NaN	8.73	0 (Flex)	28.14	0.00	32.89	0.75
Fila 3,475,223 (Fin)	2025-01-31 23:26:59	2025-01-31 23:43:01	144 → 246	NaN	2.64	0 (Flex)	14.91	0.00	19.66	0.75
Fila 3,475,224 (Fin)	2025-01-31 23:14:34	2025-01-31 23:34:52	142 → 107	NaN	3.16	0 (Flex)	17.55	0.00	22.30	0.75
Fila 3,475,225 (Fin)	2025-01-31 23:56:42	2025-02-01 00:07:27	237 → 238	NaN	2.29	0 (Flex)	12.09	0.00	16.09	0.00

Estadísticas de Resumen en Datos Crudos vs. Datos Limpios

Se calcularon la **media, mediana, moda, desviación estándar, mínimo, cuartiles (Q1, Q3) y máximo** de todas las columnas numéricas antes y después de la limpieza. Los estadísticos en bruto demuestran la presencia severa de errores de captura (por ejemplo, distancias máximas de 276,423.57 millas, tarifas de $863,372.12 USD y duraciones negativas de -51,472.32 minutos que disparan la desviación estándar):

Variable Numérica	Media (Crudo)	Mediana (Crudo)	Moda (Crudo)	Desv. Est. (Crudo)	Mínimo (Crudo)	Máximo (Crudo)	Media (Limpio)	Mediana (Limpio)	Desv. Est. (Limpio)
passenger_count	1.30	1.00	1.00	0.75	0.00	9.00	1.29	1.00	0.73
trip_distance (mi)	5.86	1.67	0.00	564.60	0.00	276,423.57	3.14	1.70	4.00
duration_min (min)	15.02	11.70	9.00	38.71	-51,472.32	5,626.32	14.65	11.68	11.23
fare_amount ($)	17.08	12.11	8.60	463.47	-900.00	863,372.12	17.67	12.80	15.01
tip_amount ($)	2.96	2.45	0.00	3.78	-86.00	400.00	3.10	2.60	3.63
tolls_amount ($)	0.45	0.00	0.00	2.00	-126.94	170.94	0.47	0.00	1.95
total_amount ($)	25.61	19.95	17.70	463.66	-901.00	863,380.37	26.50	20.35	19.16
cbd_congestion_fee ($)	0.48	0.75	0.75	0.36	-0.75	0.75	0.50	0.75	0.36
fare_per_mile ($/mi)	—	—	—	—	—	—	7.88	7.17	6.88
speed_mph (mi/h)	—	—	—	—	—	—	11.31	9.62	6.47

Conteo de Frecuencias en Variables Cualitativas

Variable Categórica	Distribución de Frecuencias Exactas (3,475,226 viajes)
payment_type	• 1 (Tarjeta de Crédito): 2,444,393 (70.34%) | • 0 (Flex Fare): 540,149 (15.54%) | • 2 (Efectivo): 390,429 (11.23%) | • 4 (Disputa): 76,481 (2.20%) | • 3 (Sin cargo): 23,773 (0.68%)
RatecodeID	• 1 (Tarifa Estándar): 2,756,472 (79.32%) | • NaN (Flex Fare): 540,149 (15.54%) | • 2 (JFK Airport): 94,420 (2.72%) | • 99 (Desconocido): 41,963 (1.21%) | • 5 (Negociada): 26,501 (0.76%) | • 3 (Newark): 8,622 (0.25%)
VendorID	• 2 (Curb Mobility, LLC): 2,719,860 (78.26%) | • 1 (Creative Mobile Tech): 753,671 (21.69%) | • 7 (Helix): 1,206 (0.03%) | • 6 (Myle): 489 (0.01%)
Top 5 Zonas (PULocationID)	• 161 (Midtown Center): 159,790 (4.99%) | • 237 (Upper East Side South): 156,836 (4.90%) | • 236 (Upper East Side North): 148,634 (4.64%) | • 132 (JFK Airport): 127,574 (3.98%) | • 230 (Times Sq): 116,993 (3.65%)

4.2. Limpieza de Datos y Manejo de Valores Nulos (3.2)

Siguiendo los 5 pasos de limpieza de datos de la metodología (pág. 20):

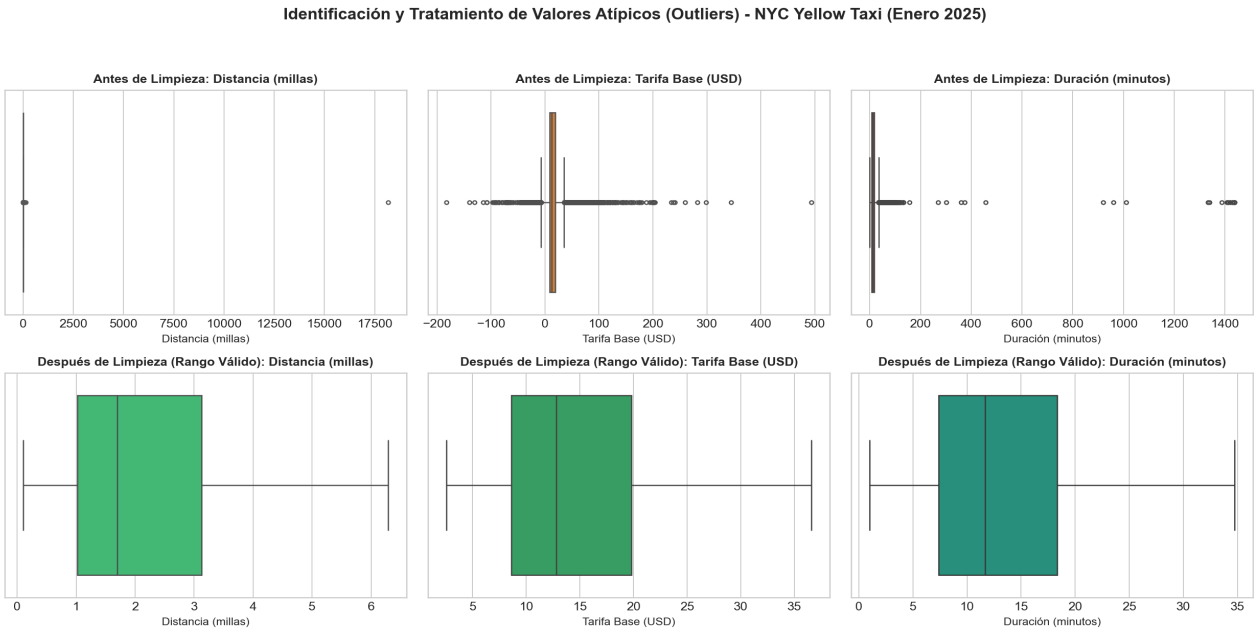
- **1. Eliminación de variables redundantes:** Se descarta store_and_fwd_flag (99.7% constante en 'N' sin aporte analítico para movilidad) y mta_tax / improvement_surcharge como columnas individuales (ya están integradas en total_amount y no varían entre viajes).
- **2. Verificación de umbral de valores nulos (< 40%):** Ninguna columna supera el umbral máximo del 40% de nulos. Exactamente 5 columnas presentan **540,149 valores nulos (15.54%)** correspondientes a viajes de tarifa flexible.
- **3. Imputación y reemplazo de datos faltantes:** En lugar de eliminar el 15.54% de los viajes (lo que sesgaría el volumen total de tráfico), se imputa passenger_count con la **mediana/moda = 1 pasajero** (al igual que cuando passenger_count = 0 en 24,656 casos), congestion_surcharge y Airport_fee con **$0.00** cuando son nulos, y RatecodeID nulo o 99 se recodifica a **1 (Estándar)**.

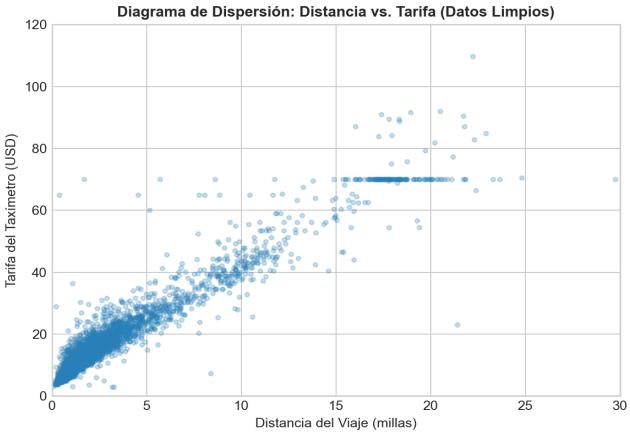
- **4. Depuración del catálogo geográfico (taxi_zone_lookup.csv):** Se detectaron los códigos LocationID = 264 (*Unknown* / *NaN*) y LocationID = 265 (*Outside of NYC* / *NaN*). Se filtran los viajes cuyo origen o destino sea 264 o 265 (9,521 en origen y 24,062 en destino) para garantizar una unión (JOIN) 100% íntegra con los 263 polígonos del mapa.
- **5. Estandarización de formatos:** Conversión de fechas a formato ISO 8601 (YYYY-MM-DD HH:MM:SS) filtrando estrictamente el mes de Enero 2025 (eliminando 22 registros desfasados de otros años/meses).

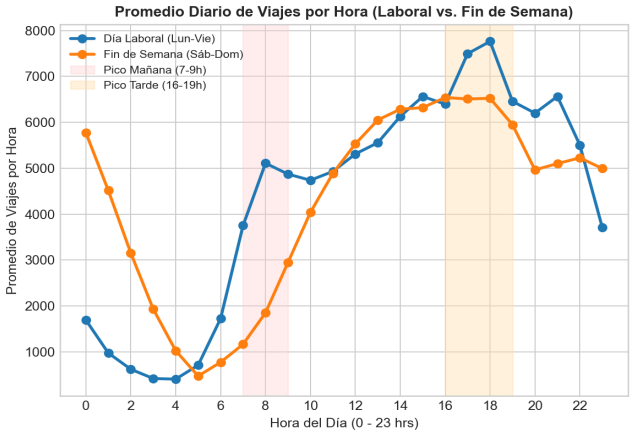
4.3. Manejo y Eliminación de Valores Atípicos / Outliers (3.3)

En un dataset de taxímetros electrónicos, existen valores atípicos generados por fallos de GPS, cobros revertidos (negativos) o taxímetros encendidos por accidente. Se establecieron reglas de dominio físico y económico apoyadas en **diagramas de caja y bigotes** y **diagramas de dispersión**:

Variable Analizada	Anomalía / Outlier Detectado en Bruto	Registros Afectados	Criterio de Validez Aplicado (Rango Conservado)
Duración (duration_min)	Tiempos negativos (-51,472 min), viajes abortados (< 1 min) o taxímetros olvidados (> 3 horas).	40,111 (< 1 min) 1,377 (> 180 min)	Se conservan viajes entre **1.0 y 180.0 minutos**.
Distancia (trip_distance)	Viajes estáticos (0 millas) o errores de odómetro (hasta 276,423.57 millas).	90,893 (≤ 0 mi) 162 (> 100 mi)	Se conservan distancias entre **0.10 y 100.0 millas**.
Tarifa Base (fare_amount)	Reembolsos/disputas negativas (hasta -$900) o errores de captura ($863,372.12 USD).	145,516 (≤ $0) 55 (> $500)	Se conservan tarifas entre **$2.50 (banderazo mínimo) y $500.00 USD**.
Velocidad (speed_mph)	Velocidades físicamente imposibles en ciudad (> 75 mph, hasta 1,043 mph por saltos de GPS).	1,345 (< 1 o > 75 mph)	Se conservan velocidades comerciales entre **1.0 y 75.0 mph**.
Propinas (tip_amount)	Propinas en efectivo aparecen como $0.00 por diseño del sistema TLC.	390,429 viajes en efectivo	Para el KPI y gráficos de propinas se filtra payment_type = 1 (Tarjeta) y tip_amount ≥ 0.




Diagrama de Dispersión: Distancia vs. Tarifa (Datos Limpios)
Tarifa del Taximetro (USD)
Distancia del Viaje (millas)
0
20
40
60
80
100
120
0
5
10
15
20
25
30


Promedio Diario de Viajes por Hora (Laboral vs. Fin de Semana)
Día Laboral (Lun-Vie)
Fin de Semana (Sáb-Dom)
Pico Mañana (7-9h)
Pico Tarde (16-19h)
Promedio de Viajes por Hora
Hora del Día (0 - 23 hrs)
1000
2000
3000
4000
5000
6000
7000
8000
0
2
4
6
8
10
12
14
16
18
20
22

4.4. Integración de Datos de Múltiples Fuentes y Esquema en PostgreSQL (3.4)

A diferencia de proyectos con una sola tabla, este sistema integra **tres fuentes de datos heterogéneas** de la NYC TLC: (1) los registros transaccionales de viajes en formato Parquet, (2) el catálogo maestro de zonas en CSV y (3) la cartografía vectorial Shapefile (reproyectada de EPSG:2263 NAD83 Feet a coordenadas web estándar EPSG:4326 WGS84).

Diseño del Esquema Relacional en PostgreSQL

```
-- 1. Tabla Dimensional de Zonas Geográficas (Integración CSV + Shapefile GeoJSON)
CREATE TABLE dim_taxi_zones (
    location_id INT PRIMARY KEY,
    borough VARCHAR(50) NOT NULL,
    zone_name VARCHAR(100) NOT NULL,
    service_zone VARCHAR(50),
    geojson_polygon JSONB
);

-- 2. Tabla de Hechos de Viajes Limpios y Enriquecidos (Parquet Procesado)
CREATE TABLE fact_taxi_trips (
    trip_id BIGSERIAL PRIMARY KEY,
    vendor_id SMALLINT NOT NULL,
    pickup_datetime TIMESTAMP NOT NULL,
    dropoff_datetime TIMESTAMP NOT NULL,
    pickup_date DATE NOT NULL,
    pickup_hour SMALLINT NOT NULL CHECK (pickup_hour BETWEEN 0 AND 23),
    day_of_week SMALLINT NOT NULL,
    is_weekend BOOLEAN NOT NULL,
    is_peak_hour BOOLEAN NOT NULL,
    pu_location_id INT NOT NULL REFERENCES dim_taxi_zones(location_id),
    do_location_id INT NOT NULL REFERENCES dim_taxi_zones(location_id),
    passenger_count SMALLINT NOT NULL,
    trip_distance NUMERIC(6,2) NOT NULL,
    duration_min NUMERIC(6,2) NOT NULL,
    speed_mph NUMERIC(5,2) NOT NULL,
    fare_amount NUMERIC(7,2) NOT NULL,
    tip_amount NUMERIC(7,2) NOT NULL,
    tolls_amount NUMERIC(6,2) NOT NULL,
    cbd_congestion_fee NUMERIC(4,2) NOT NULL,
    total_amount NUMERIC(7,2) NOT NULL,
    fare_per_mile NUMERIC(6,2) NOT NULL,
    payment_type SMALLINT NOT NULL
);

-- Índices Analíticos para Consultas Rápidas desde el Frontend en React
CREATE INDEX idx_trips_pickup_date_hour ON fact_taxi_trips(pickup_date, pickup_hour);
CREATE INDEX idx_trips_pu_location ON fact_taxi_trips(pu_location_id);
CREATE INDEX idx_trips_peak_weekend ON fact_taxi_trips(is_peak_hour, is_weekend);
```

Resumen de KPIs Base Obtenidos tras el Preprocesamiento (Enero 2025)

Indicador Clave de Rendimiento (KPI)	Valor Calculado (Datos Limpios)	Hallazgo Analítico Inicial
1. Duración Promedio de Viaje	14.65 min (Mediana: 11.68 min)	En hora pico sube a 14.96 min y la velocidad cae de 11.74 a 10.27 mph (-12.5%).
2. Distancia Promedio de Viaje	3.14 millas (Mediana: 1.70 mi)	El 75% de los viajes urbanos son menores a 3.13 millas (alta concentración en Manhattan).
3. Tarifa Promedio por Milla	$7.88 USD / milla	Sube a $8.14/mi en horas pico debido al tiempo detenido en semáforos y tráfico.
4. Zona con Mayor Demanda	Midtown Center (ID 161) - 159,790 viajes	Seguida por Upper East Side South (156,836) y Upper East Side North (148,634).
5. Propina Promedio (Pagos con Tarjeta)	$3.10 USD (Mediana: $2.60 USD)	En horas pico promedia $3.20 USD frente a $3.06 USD en horas valle.