Universidad del Caribe

2000 CANCUN, QUINTANA ROO, MÉXICO

CONOCIMIENTO Y CULTURA PARA EL DESARROLLO HUMANO

2. Dashboard interactivo en React | FASE 1

Estudiantes: Abiel Gustavo Buenrostro Avila 230300759

Naomi Elena Ramirez Rendon 230300741

Asignatura: Visualización de datos

Profesor: Jessica Carmin Mendiola Fuentes

Programa educativo: IDeIO

Fecha de entrega: 04 de noviembre del 2026

PROYECTO 4:
"LA MOVILIDAD URBANA Y EL TRÁFICO INTELIGENTE"

Fase 1: Análisis de Requerimientos y Preprocesamiento de Datos

Rubro	Detalle del Proyecto
Integrantes del equipo	Abiel Gustavo Buenrostro Avila (230300759) Naomi Elena Ramirez Rendon (230300741)
Tema	Transporte, ciudades inteligentes y sostenibilidad urbana
Fuente de datos	NYC Taxi & Limousine Commission (TLC) Trip Record Data (Enero 2025)
Registros procesados	3,475,226 viajes en bruto; 3,202,368 viajes limpios (92.15% retenido) y 265 zonas
Frontend	React 18, TypeScript, Vite, Tailwind CSS, Recharts y React-Leaflet
Base de datos	PostgreSQL 16 con extensión espacial PostGIS
Repositorio y despliegue	GitHub público y despliegue web en Vercel
Metodología	Creación de un panel de control por fases (Jessica Mendiola, 2023)

Contenido del documento:

1. Arquitectura técnica del proyecto.
2. Tarea 1: Requerimientos de la audiencia y desglose de preguntas en visualizaciones.
3. Tarea 2: Objetivo del dashboard y justificación del tipo de panel.
4. Tarea 3: Preprocesamiento de datos (identificación de variables, limpieza, valores atípicos e integración en PostgreSQL).

1. Arquitectura técnica del proyecto

Este documento presenta los resultados de la Fase 1 (Análisis) del Proyecto 4, "La movilidad urbana y el tráfico inteligente". Trabajamos con los registros de viajes de taxis amarillos de Nueva York publicados por la NYC Taxi and Limousine Commission (TLC) para medir horarios de congestión, zonas con mayor demanda de pasajeros, costos por milla y propinas.

Componente	Herramienta elegida	Motivo de la elección
Control de versiones	GitHub y Vercel	El repositorio público en GitHub permite trabajar en equipo mediante ramas y publicar los cambios directo en Vercel.
Frontend	React, Vite, Tailwind CSS, Recharts y Leaflet	React actualiza los gráficos y el mapa cuando el usuario cambia un filtro (como distrito u hora pico) sin recargar toda la página.
Base de datos	PostgreSQL con PostGIS	Soporta millones de filas indexadas, calcula promedios y cuartiles desde SQL y guarda los polígonos de las 263 zonas de taxi.
Preprocesamiento	Python (PyArrow, Pandas y GeoPandas)	Lee el archivo original en formato Parquet, filtra registros con errores de taxímetro y carga las tablas limpias en PostgreSQL.

2. Tarea 1: Analizar e identificar requerimientos de la audiencia

2.1. Perfil de la audiencia

Pregunta guía	Respuesta para este proyecto
1. ¿A quién va dirigido el dashboard y qué conoce sobre el tema?	Va dirigido a dos perfiles: primero, planificadores urbanos y personal técnico de tránsito (como el departamento de transporte o la TLC); segundo, coordinadores de flotas de taxis y analistas de datos urbanos. Ambos perfiles conocen los términos habituales del sector: horas pico, horas valle, tarifa por milla, recargo por congestión (CBD Congestion Fee), velocidad promedio en millas por hora y la división de Nueva York en 5 distritos (Boroughs) y 263 zonas.
2. ¿Qué información necesitan y qué decisiones tomarán?	Los planificadores urbanos necesitan ubicar en qué barrios se concentran las salidas de viajes y a qué horas cae la velocidad de circulación. Con esos datos deciden ajustes en tarifas de congestión, carriles preferentes o tiempos de semáforos. Por su parte, los coordinadores de flota buscan saber en qué zonas y horarios se obtiene mejor tarifa por milla y mejores propinas para enviar más unidades a puntos como Midtown, Upper East Side o el aeropuerto JFK.
3. ¿Tienen conocimiento previo sobre visualizaciones de datos?	Sí, están acostumbrados a leer reportes estadísticos y mapas. Por eso el panel emplea gráficos directos: un mapa de calor por zonas, series de líneas para ver el flujo por hora y día, histogramas para revisar tarifas y distancias, y diagramas de caja (boxplots) para comparar tiempos de traslado entre horas pico y horas valle.
4. ¿Cuáles son sus expectativas?	Esperan poder filtrar los datos por franja horaria, tipo de día (entre semana o fin de semana) y distrito para consultar al instante cómo cambian la duración del viaje, el costo por milla y la demanda por zona.

2.2. Desglose de preguntas clave en columnas y cálculos

Cada pregunta de la audiencia se resuelve combinando columnas específicas de los archivos de la TLC con una operación matemática:

Pregunta de la audiencia	Columnas utilizadas	Cálculo aplicado	Gráfico o indicador en el dashboard
1. ¿Qué zonas y distritos concentran más inicios de viaje?	PULocationID (viajes), LocationID, Borough, Zone (catálogo CSV) y geometry (shapefile)	Conteo de viajes por zona: COUNT(trip_id) y porcentaje sobre el total del mes	KPI de zona con mayor demanda, mapa de calor y gráfico de barras con el top 10 de zonas
2. ¿Cómo cambia el número de viajes según la hora del día y entre semana frente al fin de semana?	tpep_pickup_datetime (extrayendo hora de 0 a 23, fecha y día de la semana)	Conteo total por fecha y promedio diario de viajes por cada hora: AVG(viajes_hora)	Gráfico de líneas de viajes por hora y serie diaria del mes
3. ¿Cuánto tardan los viajes y cuánto aumenta ese tiempo en hora pico frente a hora valle?	tpep_pickup_datetime, tpep_dropoff_datetime, trip_distance e indicador de hora pico	Resta de tiempos en minutos: (dropoff - pickup)/60, promedio (AVG) y cuartiles (mínimo, Q1, mediana, Q3, máximo)	KPIs de duración y distancia promedio, más boxplot comparativo entre hora pico y hora valle
4. ¿Cuál es la tarifa promedio por milla y en qué rangos se concentran las tarifas y distancias?	fare_amount, total_amount y trip_distance	Promedio de la división: AVG(fare_amount / trip_distance) y conteo por intervalos (bins)	KPI de tarifa promedio por milla e histogramas de tarifas y distancias
5. ¿Cuánto dejan de propina los pasajeros según la zona de salida y el tipo de día?	tip_amount, payment_type (igual a 1, pago con tarjeta), PULocationID y tipo de día	Promedio simple: AVG(tip_amount) y proporción frente a la tarifa base	KPI de propina promedio y gráfico de barras comparativo por distrito y tipo de día

3. Tarea 2: Establecer el objetivo y el tipo de dashboard

3.1. Objetivo del dashboard y problema que atiende

El objetivo del proyecto es construir un dashboard web en React conectado a PostgreSQL para analizar los viajes en taxi de Nueva York, mostrando en qué zonas se concentra la demanda, en qué horarios baja la velocidad de traslado por el tráfico y cómo varían los costos y propinas.

El problema que resuelve es práctico: los archivos mensuales de la TLC tienen más de tres millones de filas en formato Parquet que no se pueden interpretar a simple vista y contienen registros erróneos de taxímetro. Al limpiar esa base y resumirla en indicadores visuales, el usuario puede ver de inmediato que en las horas pico entre semana la velocidad promedio cae un 12.5% (de 11.74 a 10.27 mph) y que diez zonas de Manhattan y Queens concentran casi el 40% de las salidas.

3.2. Selección y justificación del tipo de dashboard

Clasificación	Tipo elegido	Justificación
Por nivel de decisión (Operativo, Táctico o Estratégico)	Táctico	Un panel operativo requiere datos en vivo minuto a minuto para despachar unidades al instante, mientras que uno estratégico resume metas anuales para directivos. Nuestro panel es táctico porque trabaja con cortes mensuales y semanales por franja horaria, que es el nivel que usan los coordinadores de movilidad para ajustar turnos de flota, tarifas y medidas viales a mediano plazo.
Por función analítica (Metodología de Mendiola, 2023)	Analítico	Procesa un volumen alto de datos históricos (3.2 millones de viajes limpios) para encontrar patrones por hora, comparar distribuciones mediante cuartiles y cruzar zonas geográficas. Su nivel de complejidad técnica es intermedio.

3.3. Características del dashboard según los 8 criterios de la metodología

#	Criterio	Selección	Aplicación en el proyecto
1	Alcance	Específico	Trata únicamente sobre el servicio de taxis amarillos y la movilidad vial en Nueva York.
2	Tipo de datos	Cuantitativos y cualitativos	Combina números continuos (distancia, minutos, monto en dólares) con categorías (distrito, zona, método de pago, tipo de día).
3	Área	Transporte urbano y finanzas operativas	Analiza tiempos de traslado y tráfico junto con el cobro por milla, recargos de congestión y propinas.
4	Tipo de medida	Con indicadores clave (KPI)	Muestra cinco tarjetas superiores con los promedios generales del periodo filtrado.
5	Tiempo	Histórico	Trabaja con los registros cerrados de enero de 2025 para medir el comportamiento habitual por día y hora.
6	Interactividad	Interactivo	El usuario puede filtrar por distrito, días laborales o fines de semana, y horas pico o valle.
7	Nivel de detalle	Alto	Va desde los promedios de toda la ciudad hasta el conteo individual de cada una de las 263 zonas.
8	Punto de vista	Exploratorio y prescriptivo	Muestra de entrada las cifras clave de congestión (modo push) y permite filtrar libremente para revisar zonas o días específicos (modo pull).

4. Tarea 3: Preprocesamiento de datos

Para esta fase procesamos los archivos oficiales de enero de 2025 de la NYC TLC: el registro de viajes yellow_tripdata_2025-01.parquet (3,475,226 filas y 20 columnas), la tabla de zonas taxi_zone_lookup.csv (265 registros) y el archivo cartográfico taxi_zones.shp (263 polígonos).

4.1. Identificación y entendimiento de las variables

La siguiente tabla clasifica las columnas del archivo de viajes en cualitativas y cuantitativas, indicando su formato y la cantidad de valores únicos encontrados en los 3,475,226 registros:

Columna	Clase de variable	Formato	Valores únicos	Significado en la base de datos
VendorID	Cualitativa	int32	4	Empresa proveedora del taxímetro (1=CMT, 2=Curb, 6=Myle, 7=Helix).
tpep_pickup_datetime	Cuantitativa temporal	datetime64	1,672,077	Fecha y hora en que inició el viaje.
tpep_dropoff_datetime	Cuantitativa temporal	datetime64	1,671,993	Fecha y hora en que terminó el viaje.
PULocationID	Cualitativa	int32	261	Zona donde subió el pasajero (claves del 1 al 265).
DOLocationID	Cualitativa	int32	260	Zona donde bajó el pasajero (claves del 1 al 265).
RatecodeID	Cualitativa	float64	7	Tarifa aplicada (1=Estándar, 2=JFK, 3=Newark, 4=Nassau/Westchester, 5=Negociada, 6=Grupal).
payment_type	Cualitativa	int64	6	Forma de pago (1=Tarjeta, 2=Efectivo, 3=Sin cobro, 4=Disputa, 0=Tarifa flexible).
store_and_fwd_flag	Cualitativa	string	2	Indica si el viaje se guardó en memoria antes de enviarse al servidor (Y/N).

Columna	Clase de variable	Formato	Valores únicos	Significado en la base de datos
passenger_count	Cuantitativa discreta	float64	10	Cantidad de pasajeros registrada por el conductor (de 0 a 9).
trip_distance	Cuantitativa continua	float64	4,545	Distancia del trayecto en millas.
fare_amount	Cuantitativa continua	float64	11,538	Tarifa calculada por tiempo y distancia en dólares (sin impuestos ni propina).
tip_amount	Cuantitativa continua	float64	4,197	Propina en dólares (el sistema solo registra pagos con tarjeta).
tolls_amount	Cuantitativa continua	float64	1,234	Total de peajes pagados en el viaje (USD).
congestion_surcharge	Cuantitativa continua	float64	3	Recargo estatal por congestión en Nueva York ($2.50 USD).
cbd_congestion_fee	Cuantitativa continua	float64	3	Cargo de la MTA por entrar a la zona de alivio de congestión de Manhattan ($0.75 USD, vigente desde el 5 de enero de 2025).
Airport_fee	Cuantitativa continua	float64	7	Cargo por recoger pasajero en los aeropuertos JFK o LaGuardia ($1.75 USD).
total_amount	Cuantitativa continua	float64	21,995	Cobro total al pasajero en dólares.
duration_min (calculada)	Cuantitativa continua	float64	18,410	Minutos transcurridos entre el inicio y el fin del viaje.

Muestra visual: primeras 5 filas y últimas 5 filas

Al revisar el inicio y el final del archivo Parquet encontramos una diferencia importante. Las primeras filas tienen todos sus campos completos, pero las últimas 540,149 filas corresponden a viajes con tarifa flexible (payment_type = 0). En esos registros las columnas passenger_count, RatecodeID, store_and_fwd_flag, congestion_surcharge y Airport_fee aparecen vacías (NaN), aunque sí tienen fechas, zonas de origen y destino, distancia y monto cobrado:

Fila	Inicio (pickup)	Fin (dropoff)	Origen / Destino	Pasajeros	Distancia (mi)	Pago	Tarifa ($)	Propina ($)	Total ($)	Cargo CBD ($)
0	2025-01-01 00:18:38	2025-01-01 00:26:59	229 a 237	1.0	1.60	1 (Tarjeta)	10.00	3.00	18.00	0.00
1	2025-01-01 00:32:40	2025-01-01 00:35:13	236 a 237	1.0	0.50	1 (Tarjeta)	5.10	2.02	12.12	0.00
2	2025-01-01 00:44:04	2025-01-01 00:46:01	141 a 141	1.0	0.60	1 (Tarjeta)	5.10	2.00	12.10	0.00
3	2025-01-01 00:14:27	2025-01-01 00:20:01	244 a 244	3.0	0.52	2 (Efectivo)	7.20	0.00	9.70	0.00
4	2025-01-01 00:21:34	2025-01-01 00:25:06	244 a 116	3.0	0.66	2 (Efectivo)	5.80	0.00	8.30	0.00
3,475,221	2025-01-31 23:01:48	2025-01-31 23:16:29	79 a 237	NaN	3.35	0 (Flex)	15.85	0.00	20.60	0.75
3,475,222	2025-01-31 23:50:29	2025-02-01 00:17:27	161 a 116	NaN	8.73	0 (Flex)	28.14	0.00	32.89	0.75
3,475,223	2025-01-31 23:26:59	2025-01-31 23:43:01	144 a 246	NaN	2.64	0 (Flex)	14.91	0.00	19.66	0.75
3,475,224	2025-01-31 23:14:34	2025-01-31 23:34:52	142 a 107	NaN	3.16	0 (Flex)	17.55	0.00	22.30	0.75
3,475,225	2025-01-31 23:56:42	2025-02-01 00:07:27	237 a 238	NaN	2.29	0 (Flex)	12.09	0.00	16.09	0.00

Estadísticas de resumen (datos en bruto frente a datos limpios)

Calculamos la media, mediana, moda, desviación estándar, mínimo y máximo de las columnas numéricas. En los datos sin limpiar, unos pocos registros con fallas de captura alteran por completo la desviación estándar: aparecen distancias de 276,423.57 millas, cobros de $863,372.12 dólares y tiempos negativos de -51,472.32 minutos. En las últimas tres columnas de la tabla se observa cómo se estabilizan las cifras tras aplicar las reglas de limpieza:

Columna	Media (bruto)	Mediana (bruto)	Moda (bruto)	Desv. Est. (bruto)	Mínimo (bruto)	Máximo (bruto)	Media (limpio)	Mediana (limpio)	Desv. Est. (limpio)
passenger_count	1.30	1.00	1.00	0.75	0.00	9.00	1.29	1.00	0.73
trip_distance (mi)	5.86	1.67	0.00	564.60	0.00	276,423.57	3.14	1.70	4.00
duration_min (min)	15.02	11.70	9.00	38.71	-51,472.32	5,626.32	14.65	11.68	11.23
fare_amount ($)	17.08	12.11	8.60	463.47	-900.00	863,372.12	17.67	12.80	15.01
tip_amount ($)	2.96	2.45	0.00	3.78	-86.00	400.00	3.10	2.60	3.63
tolls_amount ($)	0.45	0.00	0.00	2.00	-126.94	170.94	0.47	0.00	1.95
total_amount ($)	25.61	19.95	17.70	463.66	-901.00	863,380.37	26.50	20.35	19.16

Columna	Media (bruto)	Mediana (bruto)	Moda (bruto)	Desv. Est. (bruto)	Mínimo (bruto)	Máximo (bruto)	Media (limpio)	Mediana (limpio)	Desv. Est. (limpio)
cbd_congestion_fee ($)	0.48	0.75	0.75	0.36	-0.75	0.75	0.50	0.75	0.36
fare_per_mile ($/mi)	Sin dato	Sin dato	Sin dato	Sin dato	Sin dato	Sin dato	7.88	7.17	6.88
speed_mph (mi/h)	Sin dato	Sin dato	Sin dato	Sin dato	Sin dato	Sin dato	11.31	9.62	6.47

Frecuencias de las variables categóricas

Variable	Conteo de valores en el mes (3,475,226 registros)
payment_type	1 (Tarjeta): 2,444,393 (70.34%) | 0 (Flex Fare): 540,149 (15.54%) | 2 (Efectivo): 390,429 (11.23%) | 4 (Disputa): 76,481 (2.20%) | 3 (Sin cargo): 23,773 (0.68%)
RatecodeID	1 (Estándar): 2,756,472 (79.32%) | NaN (Flex Fare): 540,149 (15.54%) | 2 (JFK): 94,420 (2.72%) | 99 (Sin definir): 41,963 (1.21%) | 5 (Negociada): 26,501 (0.76%) | 3 (Newark): 8,622 (0.25%)
VendorID	2 (Curb Mobility): 2,719,860 (78.26%) | 1 (Creative Mobile Tech): 753,671 (21.69%) | 7 (Helix): 1,206 (0.03%) | 6 (Myle): 489 (0.01%)
Zonas con más salidas	161 (Midtown Center): 159,790 (4.99%) | 237 (Upper East Side South): 156,836 (4.90%) | 236 (Upper East Side North): 148,634 (4.64%) | 132 (JFK Airport): 127,574 (3.98%) | 230 (Times Sq): 116,993 (3.65%)

4.2. Proceso de limpieza de datos

Aplicamos cinco reglas de limpieza sobre las fuentes de datos siguiendo los pasos de la metodología:

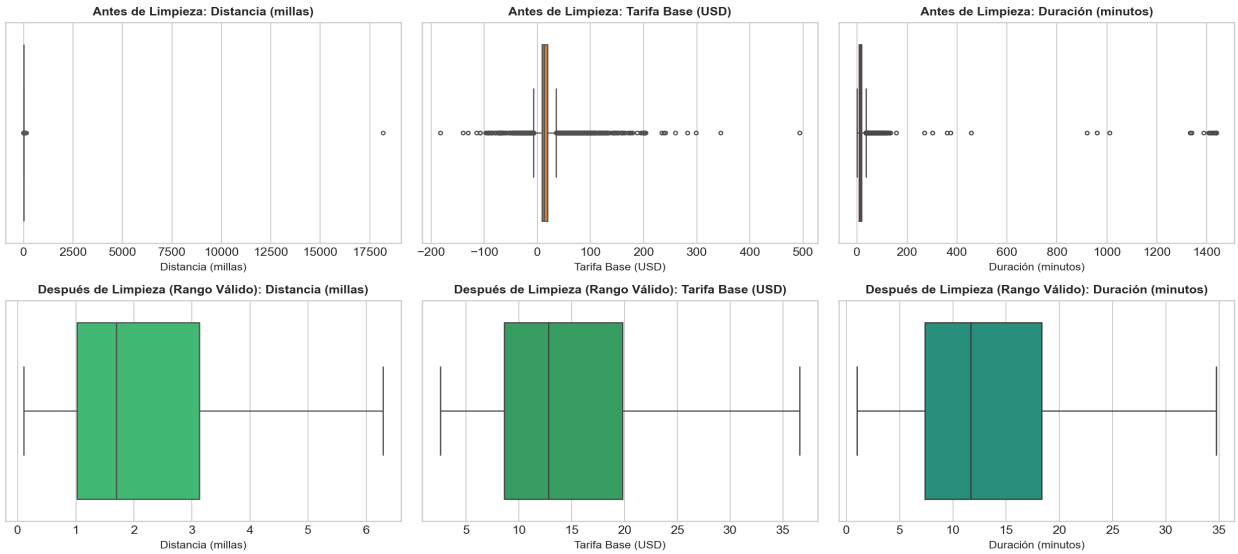
1. Columnas redundantes: Quitamos store_and_fwd_flag porque el 99.7% de los registros con dato tienen el valor 'N' y no aporta información sobre el tráfico. Tampoco cargamos por separado mta_tax ni improvement_surcharge en la tabla final porque son cargos fijos ($0.50 y $1.00) que ya vienen sumados en total_amount.
2. Revisión de valores nulos (umbral del 40%): Ninguna columna llega al 40% de datos vacíos. Cinco columnas tienen exactamente 540,149 valores nulos (15.54% del total), todos pertenecientes a los viajes de tarifa flexible.
3. Reemplazo de valores faltantes: Si borráramos ese 15.54% de filas perderíamos más de medio millón de viajes reales. En su lugar, rellenamos passenger_count con la mediana y moda del conjunto (1 pasajero, aplicando el mismo ajuste a los 24,656 viajes que tenían 0 pasajeros). En congestion_surcharge y Airport_fee reemplazamos los nulos por $0.00, y en RatecodeID asignamos el código 1 (tarifa estándar).
4. Zonas sin polígono en el catálogo: En taxi_zone_lookup.csv la clave 264 aparece como Unknown (con zona nula) y la 265 como Outside of NYC (con distrito nulo). Como el archivo taxi_zones.shp solo tiene polígonos del 1 al 263, descartamos los viajes con origen o destino en 264 o 265 (9,521 salidas y 24,062 llegadas). Además, como las zonas Corona (claves 56 y 57) y Governor's Island/Ellis Island/Liberty Island (claves 103, 104 y 105) repiten el mismo nombre en distintos polígonos, todas las uniones se hacen por LocationID.
5. Formato de fechas: Estandarizamos las fechas y quitamos 22 registros cuyas marcas de tiempo estaban fuera de enero de 2025.

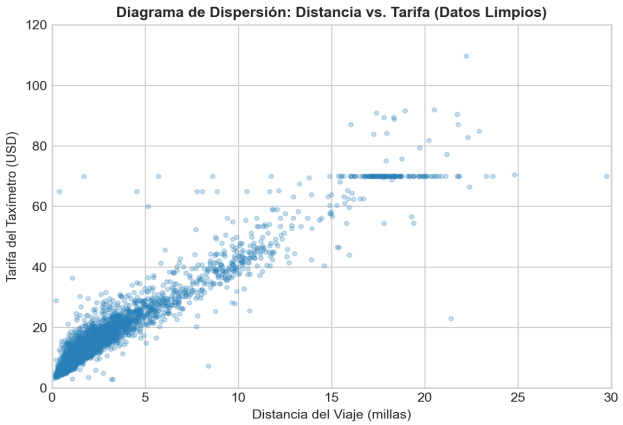
4.3. Criterios para filtrar valores atípicos (outliers)

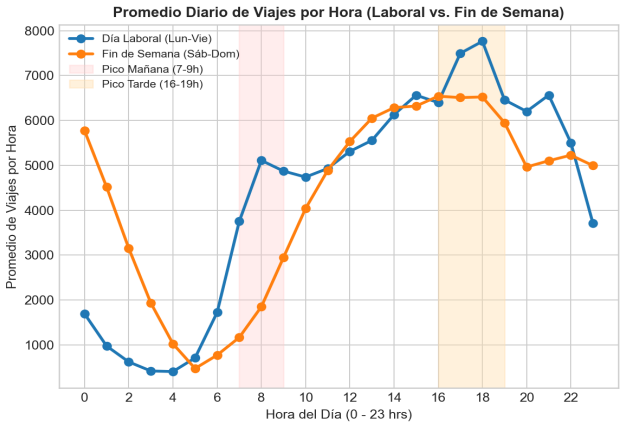
Revisamos los diagramas de caja y de dispersión para separar viajes largos reales (como traslados a los aeropuertos) de los errores de registro del taxímetro. Después de aplicar los rangos de la tabla siguiente, conservamos 3,202,368 viajes válidos (el 92.15% del archivo original) y descartamos 272,858 registros defectuosos:

Variable	Problema detectado en los datos crudos	Filas con error	Rango válido conservado
Duración (duration_min)	Fechas invertidas con tiempos negativos (-51,472 min), viajes cancelados al subir (< 1 min) o taxímetros que quedaron abiertos por días (hasta 5,626 min).	40,111 (< 1 min) 1,377 (> 180 min)	De 1.0 a 180.0 minutos (3 horas máximo).
Distancia (trip_distance)	Viajes con 0 millas o fallas de odómetro que marcan hasta 276,423.57 millas.	90,893 (<= 0 mi) 162 (> 100 mi)	De 0.10 a 100.0 millas.
Tarifa base (fare_amount)	Cobros revertidos con signo negativo (hasta -$900 USD) o montos irreales de $863,372.12 USD.	145,516 (<= $0) 55 (> $500)	De $2.50 (banderazo mínimo) a $500.00 USD.
Velocidad (speed_mph)	Trayectos donde la relación distancia/tiempo arroja más de 75 mph en ciudad (hasta 1,043 mph).	1,345 (< 1 o > 75 mph)	De 1.0 a 75.0 millas por hora.
Propina (tip_amount)	Los pagos en efectivo registran $0.00 de propina porque el taxímetro no captura propinas en billetes.	390,429 pagos en efectivo	Para calcular promedios de propina se filtra payment_type = 1 (tarjeta) y tip_amount >= 0.

Identificación y Tratamiento de Valores Atípicos (Outliers) - NYC Yellow Taxi (Enero 2025)







4.4. Integración de datos y estructura en PostgreSQL

El proyecto une tres fuentes distintas: el archivo Parquet de viajes, el catálogo CSV de zonas y el shapefile con los polígonos de los barrios. El archivo taxi_zones.shp original viene en la proyección plana NAD83 New York Long Island (EPSG:2263, medida en pies), por lo que en el script de carga se transforma a coordenadas geográficas WGS84 (EPSG:4326) y se guarda como GeoJSON dentro de PostgreSQL para dibujarlo directo en React con Leaflet.

Tablas e índices en PostgreSQL

```
-- 1. Catalogo de zonas (union de taxi_zone_lookup.csv y poligonos de taxi_zones.shp en EPSG:4326)
CREATE TABLE dim_taxi_zones (
    location_id INT PRIMARY KEY,
    borough VARCHAR(50) NOT NULL,
    zone_name VARCHAR(100) NOT NULL,
    service_zone VARCHAR(50),
    geojson_polygon JSONB
);

-- 2. Tabla de viajes limpios (yellow_tripdata_2025-01.parquet procesado)
CREATE TABLE fact_taxi_trips (
    trip_id BIGSERIAL PRIMARY KEY,
    vendor_id SMALLINT NOT NULL,
    pickup_datetime TIMESTAMP NOT NULL,
    dropoff_datetime TIMESTAMP NOT NULL,
    pickup_date DATE NOT NULL,
    pickup_hour SMALLINT NOT NULL CHECK (pickup_hour BETWEEN 0 AND 23),
    day_of_week SMALLINT NOT NULL,
    is_weekend BOOLEAN NOT NULL,
    is_peak_hour BOOLEAN NOT NULL,
    pu_location_id INT NOT NULL REFERENCES dim_taxi_zones(location_id),
    do_location_id INT NOT NULL REFERENCES dim_taxi_zones(location_id),
    passenger_count SMALLINT NOT NULL,
    trip_distance NUMERIC(6,2) NOT NULL,
    duration_min NUMERIC(6,2) NOT NULL,
    speed_mph NUMERIC(5,2) NOT NULL,
    fare_amount NUMERIC(7,2) NOT NULL,
    tip_amount NUMERIC(7,2) NOT NULL,
    tolls_amount NUMERIC(6,2) NOT NULL,
    cbd_congestion_fee NUMERIC(4,2) NOT NULL,
    total_amount NUMERIC(7,2) NOT NULL,
    fare_per_mile NUMERIC(6,2) NOT NULL,
    payment_type SMALLINT NOT NULL
);

-- Indices para acelerar los filtros del dashboard
CREATE INDEX idx_trips_pickup_date_hour ON fact_taxi_trips(pickup_date, pickup_hour);
CREATE INDEX idx_trips_pu_location ON fact_taxi_trips(pu_location_id);
CREATE INDEX idx_trips_peak_weekend ON fact_taxi_trips(is_peak_hour, is_weekend);
```

Resumen de indicadores calculados con la base limpia (enero 2025)

Indicador (KPI)	Resultado en datos limpios	Comportamiento observado
Duración promedio de viaje	14.65 minutos (mediana: 11.68 min)	En hora pico sube a 14.96 min y la velocidad baja de 11.74 a 10.27 mph (-12.5%).
Distancia promedio de viaje	3.14 millas (mediana: 1.70 mi)	Tres cuartas partes de los viajes miden menos de 3.13 millas.
Tarifa promedio por milla	$7.88 USD / milla	Aumenta a $8.14/mi en horas pico por el tiempo que el taxi pasa detenido en tráfico.
Zona con mayor demanda	Midtown Center (ID 161) con 159,790 viajes	Le siguen Upper East Side South (156,836) y Upper East Side North (148,634).
Propina promedio (pagos con tarjeta)	$3.10 USD (mediana: $2.60 USD)	En horas pico promedia $3.20 USD frente a $3.06 USD en horas valle.